观行知意：人体日常行为识别挑战赛

模型测评计分规则

第一条　总则与基本概念

(1) **适用范围**。本规则适用于无界杯 UESTC AI 挑战赛 A 题的模型测评、项目成果计分及相关提交。

(2) **识别任务**。模型根据一段动作片段，判断其中的人物正在进行哪一种日常动作。任务共设 40 个动作类别，类别编号及顺序以数据包清单为准。

(3) **数据与模态**。比赛提供深度伪彩图（Depth_Color）与红外图像（IR）两种模态。每段片段最多包含 32 对同步图像，分辨率为 304×228。参赛队伍可使用其中一种或两种模态；任务训练与推理仅使用本届提供的深度图和 IR，不引入额外模态。

(4) **数据划分**。训练集含 1,995 段，公开验证集含 466 段，组织方测试集含 470 段。三者按人物划分，人物不跨集合。训练集用于模型训练，公开验证集用于方法比较与参数选择，组织方测试集用于正式提交后的统一测评。

(5) **测评单元**。一次完整测评包含组织方测试集的全部动作片段。模型逐段接收匿名图像目录，输出按固定类别顺序排列的 40 个有限数值。取最高分对应的类别作为预测；最高分相同时，取最小类别编号。

(6) **项目成果分**。项目成果满分 100 分，由基准分、提升分、类别表现分和推理效率分组成。各项按同一次完整测评的结果计算。

(7) **基线模型**。基线模型指组织方发布并冻结代码、权重和运行配置的参考模型，用于确定准确率及推理延迟参考值。

第二条　指标与计时

(1) **准确率**。设测试集片段数为 N，预测正确的片段数为 N_{correct}，准确率为

$$A = 100\,\frac{N_{\text{correct}}}{N}.$$

(2) **类别表现**。对固定的 40 个类别分别计算 F1，再取算术平均。设类别 c 的真阳性、假阳性和假阴性数分别为 TP_c、FP_c、FN_c，则

$$F = \frac{100}{40}\sum_{c=1}^{40}\frac{2\text{TP}_c}{2\text{TP}_c + \text{FP}_c + \text{FN}_c}.$$

分母为零时，该类别的 F1 记为 0。

(3) **推理延迟**。首个片段用于计时预热，其预测仍计入准确率与类别表现。其余片段的预测耗时取算术平均，记为 L，单位为毫秒 / 片段。

(4) **计时范围**。单片段耗时包含图像读取、预处理、人物检测、分类、CUDA 同步与选手进程通信。平台下载与数据准备、模型初始化不计入 L。

表 1：主要符号与含义

符号	含义	单位
A	本次测评准确率	百分数数值
F	本次测评 Macro F1	百分数数值
L	本次测评平均推理延迟	毫秒 / 片段
B	冻结基线在同版测试集上的准确率	百分数数值
G	提升分达到上限所需的准确率增量	百分点
T	冻结基线的推理延迟参考值	毫秒 / 片段

例如，准确率为 65% 时，公式中取 $A = 65$。

第三条　项目成果计分

(1) **基准比例**。定义 $q = \min(A/B, 1)$，其中 $0 < B < 100$。

(2) **分项计分**。四项得分按表 2 计算。准确率达到 B 时，基准分达到 60 分；准确率达到 $B + G$ 时，提升分达到 20 分。

表 2：项目成果分构成

计分项	计算公式	满分
基准分 S_{base}	$60q$	60
提升分 S_{gain}	$20\min\left(\dfrac{\max(A-B,0)}{G}, 1\right)$	20
类别表现分 S_{class}	$0.10F$	10
推理效率分 S_{eff}	$10q\min\left(1, \dfrac{T}{L}\right)$	10

(3) **项目成果分**。四项得分之和为项目成果分：

$$S_{\text{project}} = S_{\text{base}} + S_{\text{gain}} + S_{\text{class}} + S_{\text{eff}}.$$

各分项均为非负数，项目成果分上限为 100 分。计算过程保留原始精度，页面显示两位小数。

(4) **同分处理**。项目成果分相同时，依次比较准确率 A、Macro F1 F；仍相同则并列。

第四条　参考值与版本

(1) **准确率参考值。**B 由冻结基线在同版组织方测试集上的完整测评确定。基线选择与方法调试使用公开验证集。

(2) **提升幅度。**提升幅度固定为 $G = \min(15, 100 - B)$，单位为百分点。

(3) **延迟参考值。**冻结基线在统一评测 GPU 上完整运行公开验证集三次，各次按第二条计算平均延迟，取三次结果的中位数作为 T。T 与 L 使用相同 GPU 型号及计时范围，且均大于 0。

(4) **公布与固定。**正式测评前，组织方公布 B、G、T、数据版本、基线代码版本、权重校验值及评测环境。各次测评保存所用规则版本和参考值。

第五条　运行限制与提交

(1) **自行验证。**队伍在自己的电脑或 AutoDL 等计算环境中，使用训练集训练模型，使用公开验证集验证效果、比较方法。

(2) **运行时限。**单次运行上限为 1,800 秒，自评测程序领取任务、开始准备程序包时计时，包含程序包及权重准备、模型初始化与推理。排队时间不计入。

(3) **有效结果。**全部 470 段产生有效预测后计算完整成绩。输出维数错误、非有限数值、程序异常或超时使本次运行失败。平台故障由组织方依据运行记录核查，确认后安排补跑。

(4) **正式提交。**队伍通过官网提交训练及推理代码、运行配置、验证结果和技术报告 PDF，权重直接发赛事管理 QQ。组织方统一测评并复核后确认项目成果分。

(5) **材料复核。**代码包、权重、运行配置和参数清单用于复核。技术说明应包含数据处理、模型设计、训练设置、验证结果、实验分析与复现命令。

第六条　模型与数据使用

(1) **模型方法。**允许使用通用公开预训练权重微调，也可从零训练。队伍须列明权重来源及训练设置。允许使用 Coding Agent 辅助开发、调试和实验分析。

(2) **参数限制。**分类器、检测器及其他参与推理的模型合计不超过 100M 参数，冻结参数计入总量。

(3) **模态范围。**本届仅提供深度图与 IR。可调整取帧、裁剪、输入尺寸及两种模态的融合方式；额外模态不用于本任务的训练、辅助监督、蒸馏或推理。通用公开预训练权重按本条第 (1) 项使用。

(4) **数据范围。**禁止使用在 CUHK-X 上预训练或微调过的外部权重。队伍可用本届训练集自行训练或微调，公开验证集仅用于评估和模型选择。测试集及本届范围外的 CUHK-X 数据不用于训练、伪标签生成或模型选择。

第七条　违规与处置

(1) **违规行为。**包括利用测试标签、来源编号或映射表获取答案；绕过接口读取私有清单、标签或其他样本；测评中违规联网、人工介入，以及篡改预测和运行记录。选手程序在测评期间离线运行，声明的权重由平台提前准备。

(2) **认定与处理。**组织方依据代码、权重、运行日志和复现结果核查，队伍可提交说明。确认违规或参数量超限的提交无效；已据此公布的成绩、名次或奖项相应撤销或更正。

第八条　赛事成绩

(1) **成绩构成。**项目成果、技术报告 PDF 与答辩均采用百分制，分别占赛事总成绩的 **50%、10% 和 40%**。

(2) **赛事总成绩。**总成绩按下式计算：

$$S_{\text{total}} = 0.50S_{\text{project}} + 0.10S_{\text{report}} + 0.40S_{\text{defense}}.$$

(3) **研究内容。**技术说明与答辩可报告方法比较、消融实验、错例分析和研究发现，纳入对应环节评分。

第九条　附则

规则补充与问题答复在官网及比赛群统一发布。涉及数据、计分或评测环境的调整，组织方公布版本、生效时间及已有提交的处理方式。